

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«СЕВЕРО–КАВКАЗСКИЙ ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ»

Институт перспективной инженерии
Департамент цифровых, робототехнических систем и электроники

ОТЧЕТ
ПО ЛАБОРАТОРНОЙ РАБОТЕ №6
дисциплины
«Основы нейронных сетей»
Вариант 10

Выполнил:
Рябинин Егор Алексеевич
3 курс, группа ИВТ-б-о-23-2,
09.03.01 «Информатика и
вычислительная техника»,
направленность (профиль)
«Программное обеспечение средств
вычислительной техники и
автоматизированных систем», очная
форма обучения

(подпись)

Проверил:
Доцент департамента цифровых,
робототехнических систем и
электроники института перспективной
инженерии
Воронкин Роман Александрович

(подпись)

Отчет защищен с оценкой _____ Дата защиты _____

Ставрополь, 2026 г

Тема: разработка и исследование нейросетевых моделей для решения задач регрессии в средах PyTorch и TensorFlow.

Цель: изучить методологию построения, обучения и оценки нейронных сетей для задач регрессии на примерах прогнозирования заработной платы по резюме, количества фолов в баскетбольных матчах и стоимости автомобилей; провести сравнительный анализ различных архитектур нейронных сетей и фреймворков глубокого обучения.

Порядок выполнения работы:

Ссылка на репозиторий:

https://github.com/bohemiaaaaa/Lab6_Neural-networks

Pytorch:

Задание 1. На основе подготовленной для нейросети таблицы данных с HeadHunter создайте 6 архитектур нейросетей, поэкспериментируйте с гиперпараметрами. Используйте только числовые данные, текстовые не подавайте. Результаты в конце проанализируйте. Перед началом выполнения, пожалуйста, запустите раздел «Подготовка».

```
import torch
import torch.nn as nn
import torch.optim as optim
from torch.utils.data import DataLoader, TensorDataset

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import mean_absolute_error

import gdown
import re

%matplotlib inline
```

Рисунок 1 – Импорт библиотек

```
gdown.download('https://storage.yandexcloud.net/aiueducation/Content/base/l10/hh_fixed.csv', None, quiet=True)

df = pd.read_csv('hh_fixed.csv', index_col=0)
print(f"Размер данных: {df.shape}")
df.head(3)
```

Рисунок 2 – Загрузка и подготовка данных

```
COL_SEX_AGE = df.columns.get_loc('Пол, возраст')
COL_SALARY = df.columns.get_loc('ЗП')
COL_POS_SEEK = df.columns.get_loc('Ищет работу на должность:')
COL_POS_PREV = df.columns.get_loc('Последняя/нынешняя должность')
COL_CITY = df.columns.get_loc('Город')
COL_EMPL = df.columns.get_loc('Занятость')
COL_SCHED = df.columns.get_loc('График')
COL_EXP = df.columns.get_loc('Опыт (двойное нажатие для полной версии)')
COL_EDU = df.columns.get_loc('Образование и ВУЗ')
COL_UPDATED = df.columns.get_loc('Обновление резюме')
```

Рисунок 3 – Настройка номеров столбцов

```
currency_rate = {
    'usd': 65., 'kzt': 0.17, 'грн': 2.6, 'белруб': 30.5,
    'eur': 70., 'kgs': 0.9, 'сум': 0.007, 'azn': 37.5
}

age_class = [0, [18, 23, 28, 33, 38, 43, 48, 53, 58, 63]]
experience_class = [0, [7, 13, 25, 37, 61, 97, 121, 157, 193, 241]]

city_class = [0, {
    'москва': 0, 'с-петербург': 1, 'новосибирск': 2,
    'екатеринбург': 2, 'нижний новгород': 2, 'казань': 2,
    'челябинск': 2, 'омск': 2, 'самара': 2, 'ростов-на-дону': 2,
    'уфа': 2, 'красноярск': 2, 'пермь': 2, 'воронеж': 2,
    'волгоград': 2, 'прочие города': 3
}]

employment_class = [0, {
    'стажировка': 0, 'частичная занятость': 1,
    'проектная работа': 2, 'полная занятость': 3
}]

schedule_class = [0, {
    'гибкий график': 0, 'полный день': 1,
    'сменный график': 2, 'удаленная работа': 3
}]

education_class = [0, {
    'высшее образование': 0, 'higher education': 0,
    'среднее специальное': 1, 'неоконченное высшее': 2,
    'среднее образование': 3
}]

# Вычисление счетчиков
for class_desc in [age_class, experience_class, city_class,
                   employment_class, schedule_class, education_class]:
    if isinstance(class_desc[1], list):
        class_desc[0] = len(class_desc[1]) + 1
    else:
        class_desc[0] = max(class_desc[1].values()) + 1
```

Рисунок 4 – Параметрические данные

```

def extract_row_data(row):
    sex, age = extract_sex_age_years(row[COL_SEX_AGE])
    sex_vec = np.array([sex])
    age_ohe = age_years_to_ohe(age)
    city_ohe = extract_city_to_ohe(row[COL_CITY])
    empl_multi = extract_employment_to_multi(row[COL_EMPL])
    sched_multi = extract_schedule_to_multi(row[COL_SCHED])
    edu_multi = extract_education_to_multi(row[COL_EDU])
    exp_months = extract_experience_months(row[COL_EXP])
    exp_ohe = experience_months_to_ohe(exp_months)
    salary = extract_salary(row[COL_SALARY])
    salary_vec = np.array([salary])

    x_data = np.hstack([sex_vec, age_ohe, city_ohe, empl_multi,
                        sched_multi, edu_multi, exp_ohe])
    return x_data, salary_vec

def construct_train_data(row_list):
    x_data = []
    y_data = []
    for row in row_list:
        x, y = extract_row_data(row)
        if y[0] > 0:
            x_data.append(x)
            y_data.append(y)
    return np.array(x_data), np.array(y_data)

x_train_01, y_train = construct_train_data(df.values)
print(x_train_01.shape, y_train.shape)

```

Рисунок 5 – Формирование выборки

```

def plot_history(history_dict):
    plt.plot(history_dict['train_mae'], label='Train MAE', linewidth=1.5)
    plt.plot(history_dict['val_mae'], label='Val MAE', linewidth=1.5)
    plt.xlabel('Эпоха')
    plt.ylabel('MAE (нормированная)')
    plt.legend()
    plt.grid(True, alpha=0.3)
    plt.show()

```

Рисунок 6 – Функция отрисовки графика истории обучения

```

from sklearn.model_selection import train_test_split

# Масштабирование
scaler_X = StandardScaler()
X_scaled = scaler_X.fit_transform(x_train_01)

scaler_y = StandardScaler()
y_scaled = scaler_y.fit_transform(y_train)

# Разбиение
X_train, X_val, y_train_scaled, y_val_scaled = train_test_split(
    X_scaled, y_scaled, test_size=0.2, random_state=42
)

# Преобразование в тензоры
X_train_t = torch.tensor(X_train, dtype=torch.float32)
y_train_t = torch.tensor(y_train_scaled, dtype=torch.float32).reshape(-1, 1)
X_val_t = torch.tensor(X_val, dtype=torch.float32)
y_val_t = torch.tensor(y_val_scaled, dtype=torch.float32).reshape(-1, 1)

# DataLoader
train_dataset = TensorDataset(X_train_t, y_train_t)
val_dataset = TensorDataset(X_val_t, y_val_t)
train_loader = DataLoader(train_dataset, batch_size=256, shuffle=True)
val_loader = DataLoader(val_dataset, batch_size=256, shuffle=False)

print(f"Обучающая выборка: {X_train.shape[0]} samples")
print(f"Валидационная выборка: {X_val.shape[0]} samples")

```

Рисунок 7 – Подготовка данных

```

def train_model(model, train_loader, val_loader, epochs=50, lr=0.001, patience=10):
    criterion = nn.MSELoss()
    optimizer = optim.Adam(model.parameters(), lr=lr)
    scheduler = optim.lr_scheduler.ReduceLROnPlateau(optimizer, patience=3, factor=0.5)

    history = {'train_loss': [], 'val_loss': [], 'train_mae': [], 'val_mae': []}
    best_val_mae = float('inf')
    best_model_state = None
    patience_counter = 0

    for epoch in range(epochs):
        # Training
        model.train()
        train_loss = 0.0
        train_mae = 0.0
        for X_batch, y_batch in train_loader:
            optimizer.zero_grad()
            y_pred = model(X_batch)
            loss = criterion(y_pred, y_batch)
            loss.backward()
            optimizer.step()
            train_loss += loss.item() * X_batch.size(0)
            train_mae += torch.abs(y_pred - y_batch).sum().item()

        train_loss /= len(train_loader.dataset)
        train_mae /= len(train_loader.dataset)

        # Validation
        model.eval()
        val_loss = 0.0
        val_mae = 0.0
        with torch.no_grad():
            for X_batch, y_batch in val_loader:
                y_pred = model(X_batch)
                loss = criterion(y_pred, y_batch)
                val_loss += loss.item() * X_batch.size(0)
                val_mae += torch.abs(y_pred - y_batch).sum().item()

```

Рисунок 8 – Функция обучения модели

```

    val_loss /= len(val_loader.dataset)
    val_mae /= len(val_loader.dataset)

    history['train_loss'].append(train_loss)
    history['val_loss'].append(val_loss)
    history['train_mae'].append(train_mae)
    history['val_mae'].append(val_mae)

    current_lr = optimizer.param_groups[0]['lr']
    print(f"Epoch {epoch+1}/{epochs}: train_loss={train_loss:.4f}, train_mae={train_mae:.4f}, val_loss={val_loss:.4f}, val_mae={val_mae:.4f}, lr={current_lr:.6f}")

    scheduler.step(val_loss)

    # Early stopping
    if val_mae < best_val_mae:
        best_val_mae = val_mae
        best_model_state = model.state_dict().copy()
        patience_counter = 0
    else:
        patience_counter += 1
        if patience_counter >= patience:
            print(f"Early stopping at epoch {epoch+1}")
            break

    model.load_state_dict(best_model_state)

```

Рисунок 9 – Функция обучения модели

```

class Model1_Basic(nn.Module):
    def __init__(self, input_dim):
        super(Model1_Basic, self).__init__()
        self.net = nn.Sequential(
            nn.Linear(input_dim, 64),
            nn.ReLU(),
            nn.Linear(64, 1)
        )

    def forward(self, x):
        return self.net(x)

model1 = Model1_Basic(input_dim)
print(model1)
model1, history1 = train_model(model1, train_loader, val_loader, epochs=50)

```

Рисунок 10 – Архитектура №1 Базовая (1 скрытый слой)

```

Model1_Basic(
  (net): Sequential(
    (0): Linear(in_features=39, out_features=64, bias=True)
    (1): ReLU()
    (2): Linear(in_features=64, out_features=1, bias=True)
  )
)
Epoch 1/50: train_loss=0.9110, train_mae=0.5925, val_loss=0.8337, val_mae=0.5849, lr=0.001000
Epoch 2/50: train_loss=0.8850, train_mae=0.5806, val_loss=0.8288, val_mae=0.5797, lr=0.001000
Epoch 3/50: train_loss=0.8823, train_mae=0.5783, val_loss=0.8275, val_mae=0.5842, lr=0.001000
Epoch 4/50: train_loss=0.8804, train_mae=0.5773, val_loss=0.8282, val_mae=0.5806, lr=0.001000
Epoch 5/50: train_loss=0.8787, train_mae=0.5761, val_loss=0.8263, val_mae=0.5724, lr=0.001000
Epoch 6/50: train_loss=0.8783, train_mae=0.5755, val_loss=0.8255, val_mae=0.5758, lr=0.001000
Epoch 7/50: train_loss=0.8774, train_mae=0.5754, val_loss=0.8278, val_mae=0.5896, lr=0.001000
Epoch 8/50: train_loss=0.8770, train_mae=0.5755, val_loss=0.8261, val_mae=0.5814, lr=0.001000
Epoch 9/50: train_loss=0.8764, train_mae=0.5748, val_loss=0.8261, val_mae=0.5736, lr=0.001000
Epoch 10/50: train_loss=0.8765, train_mae=0.5748, val_loss=0.8241, val_mae=0.5739, lr=0.001000
Epoch 11/50: train_loss=0.8754, train_mae=0.5742, val_loss=0.8283, val_mae=0.5758, lr=0.001000
Epoch 12/50: train_loss=0.8764, train_mae=0.5751, val_loss=0.8254, val_mae=0.5785, lr=0.001000
Epoch 13/50: train_loss=0.8750, train_mae=0.5742, val_loss=0.8246, val_mae=0.5693, lr=0.001000
Epoch 14/50: train_loss=0.8748, train_mae=0.5737, val_loss=0.8269, val_mae=0.5758, lr=0.001000
Epoch 15/50: train_loss=0.8728, train_mae=0.5726, val_loss=0.8241, val_mae=0.5746, lr=0.000500
Epoch 16/50: train_loss=0.8724, train_mae=0.5734, val_loss=0.8264, val_mae=0.5708, lr=0.000500
Epoch 17/50: train_loss=0.8723, train_mae=0.5725, val_loss=0.8252, val_mae=0.5725, lr=0.000500
Epoch 18/50: train_loss=0.8719, train_mae=0.5727, val_loss=0.8250, val_mae=0.5770, lr=0.000500
...
Epoch 21/50: train_loss=0.8705, train_mae=0.5717, val_loss=0.8238, val_mae=0.5767, lr=0.000250
Epoch 22/50: train_loss=0.8702, train_mae=0.5717, val_loss=0.8240, val_mae=0.5798, lr=0.000250
Epoch 23/50: train_loss=0.8699, train_mae=0.5721, val_loss=0.8236, val_mae=0.5786, lr=0.000250
Early stopping at epoch 23
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

```

Рисунок 11 – Обучение

```

class DeepSalaryModel(nn.Module):
    def __init__(self, input_dim):
        super(DeepSalaryModel, self).__init__()
        self.net = nn.Sequential(
            nn.Linear(input_dim, 128),
            nn.ReLU(),
            nn.Linear(128, 256),
            nn.ReLU(),
            nn.Linear(256, 128),
            nn.ReLU(),
            nn.Linear(128, 64),
            nn.ReLU(),
            nn.Linear(64, 1)
        )

    def forward(self, x):
        return self.net(x)

model2 = DeepSalaryModel(input_dim)
print(model2)
model2, history2 = train_model(model2, train_loader, val_loader, epochs=50)

```

Рисунок 12 – Архитектура №2 Глубокая сеть

```

DeepSalaryModel(
  (net): Sequential(
    (0): Linear(in_features=39, out_features=128, bias=True)
    (1): ReLU()
    (2): Linear(in_features=128, out_features=256, bias=True)
    (3): ReLU()
    (4): Linear(in_features=256, out_features=128, bias=True)
    (5): ReLU()
    (6): Linear(in_features=128, out_features=64, bias=True)
    (7): ReLU()
    (8): Linear(in_features=64, out_features=1, bias=True)
  )
)
Epoch 1/50: train_loss=0.9011, train_mae=0.5876, val_loss=0.8319, val_mae=0.5673, lr=0.001000
Epoch 2/50: train_loss=0.8841, train_mae=0.5790, val_loss=0.8295, val_mae=0.5715, lr=0.001000
Epoch 3/50: train_loss=0.8827, train_mae=0.5767, val_loss=0.8264, val_mae=0.5750, lr=0.001000
Epoch 4/50: train_loss=0.8792, train_mae=0.5766, val_loss=0.8262, val_mae=0.5706, lr=0.001000
Epoch 5/50: train_loss=0.8769, train_mae=0.5749, val_loss=0.8251, val_mae=0.5808, lr=0.001000
Epoch 6/50: train_loss=0.8760, train_mae=0.5739, val_loss=0.8254, val_mae=0.5835, lr=0.001000
Epoch 7/50: train_loss=0.8750, train_mae=0.5745, val_loss=0.8256, val_mae=0.5784, lr=0.001000
Epoch 8/50: train_loss=0.8732, train_mae=0.5729, val_loss=0.8299, val_mae=0.5862, lr=0.001000
Epoch 9/50: train_loss=0.8711, train_mae=0.5730, val_loss=0.8240, val_mae=0.5709, lr=0.001000
Epoch 10/50: train_loss=0.8719, train_mae=0.5726, val_loss=0.8285, val_mae=0.5840, lr=0.001000
Epoch 11/50: train_loss=0.8697, train_mae=0.5724, val_loss=0.8264, val_mae=0.5840, lr=0.001000
Early stopping at epoch 11

```

Рисунок 13 – Обучение


```

class DropoutSalaryModel(nn.Module):
    def __init__(self, input_dim):
        super(DropoutSalaryModel, self).__init__()
        self.net = nn.Sequential(
            nn.Linear(input_dim, 128),
            nn.ReLU(),
            nn.Dropout(0.3),
            nn.Linear(128, 256),
            nn.ReLU(),
            nn.Dropout(0.3),
            nn.Linear(256, 128),
            nn.ReLU(),
            nn.Dropout(0.2),
            nn.Linear(128, 1)
        )

    def forward(self, x):
        return self.net(x)

model3 = DropoutSalaryModel(input_dim)
print(model3)
model3, history3 = train_model(model3, train_loader, val_loader, epochs=50)

```

Рисунок 14 – Архитектура №3 с Dropout

```

DropoutSalaryModel(
  (net): Sequential(
    (0): Linear(in_features=39, out_features=128, bias=True)
    (1): ReLU()
    (2): Dropout(p=0.3, inplace=False)
    (3): Linear(in_features=128, out_features=256, bias=True)
    (4): ReLU()
    (5): Dropout(p=0.3, inplace=False)
    (6): Linear(in_features=256, out_features=128, bias=True)
    (7): ReLU()
    (8): Dropout(p=0.2, inplace=False)
    (9): Linear(in_features=128, out_features=1, bias=True)
  )
)
Epoch 1/50: train_loss=0.9141, train_mae=0.5952, val_loss=0.8362, val_mae=0.5973, lr=0.001000
Epoch 2/50: train_loss=0.8954, train_mae=0.5853, val_loss=0.8291, val_mae=0.5853, lr=0.001000
Epoch 3/50: train_loss=0.8898, train_mae=0.5827, val_loss=0.8294, val_mae=0.5861, lr=0.001000
Epoch 4/50: train_loss=0.8882, train_mae=0.5815, val_loss=0.8292, val_mae=0.5783, lr=0.001000
Epoch 5/50: train_loss=0.8862, train_mae=0.5801, val_loss=0.8271, val_mae=0.5831, lr=0.001000
Epoch 6/50: train_loss=0.8835, train_mae=0.5796, val_loss=0.8275, val_mae=0.5827, lr=0.001000
Epoch 7/50: train_loss=0.8843, train_mae=0.5791, val_loss=0.8257, val_mae=0.5766, lr=0.001000
Epoch 8/50: train_loss=0.8849, train_mae=0.5788, val_loss=0.8263, val_mae=0.5803, lr=0.001000
Epoch 9/50: train_loss=0.8832, train_mae=0.5797, val_loss=0.8290, val_mae=0.5861, lr=0.001000
Epoch 10/50: train_loss=0.8821, train_mae=0.5779, val_loss=0.8318, val_mae=0.5707, lr=0.001000
Epoch 11/50: train_loss=0.8824, train_mae=0.5776, val_loss=0.8256, val_mae=0.5799, lr=0.001000
...
Epoch 18/50: train_loss=0.8759, train_mae=0.5760, val_loss=0.8245, val_mae=0.5823, lr=0.000500
Epoch 19/50: train_loss=0.8747, train_mae=0.5755, val_loss=0.8253, val_mae=0.5854, lr=0.000500
Epoch 20/50: train_loss=0.8703, train_mae=0.5760, val_loss=0.8296, val_mae=0.5923, lr=0.000500
Early stopping at epoch 20
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

```

Рисунок 15 – Обучение

```

class BatchNormSalaryModel(nn.Module):
    def __init__(self, input_dim):
        super(BatchNormSalaryModel, self).__init__()
        self.net = nn.Sequential(
            nn.BatchNorm1d(input_dim),
            nn.Linear(input_dim, 128),
            nn.BatchNorm1d(128),
            nn.ReLU(),
            nn.Linear(128, 256),
            nn.BatchNorm1d(256),
            nn.ReLU(),
            nn.Linear(256, 128),
            nn.BatchNorm1d(128),
            nn.ReLU(),
            nn.Linear(128, 1)
        )

    def forward(self, x):
        return self.net(x)

model4 = BatchNormSalaryModel(input_dim)
print(model4)
model4, history4 = train_model(model4, train_loader, val_loader, epochs=50)

```

Рисунок 16 – Архитектура №4 с BatchNormalization

```

BatchNormSalaryModel(
  (net): Sequential(
    (0): BatchNorm1d(39, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
    (1): Linear(in_features=39, out_features=128, bias=True)
    (2): BatchNorm1d(128, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
    (3): ReLU()
    (4): Linear(in_features=128, out_features=256, bias=True)
    (5): BatchNorm1d(256, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
    (6): ReLU()
    (7): Linear(in_features=256, out_features=128, bias=True)
    (8): BatchNorm1d(128, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
    (9): ReLU()
    (10): Linear(in_features=128, out_features=1, bias=True)
  )
)
Epoch 1/50: train_loss=0.9135, train_mae=0.5961, val_loss=0.8343, val_mae=0.5862, lr=0.001000
Epoch 2/50: train_loss=0.8884, train_mae=0.5812, val_loss=0.8350, val_mae=0.5910, lr=0.001000
Epoch 3/50: train_loss=0.8822, train_mae=0.5785, val_loss=0.8288, val_mae=0.5774, lr=0.001000
Epoch 4/50: train_loss=0.8810, train_mae=0.5778, val_loss=0.8282, val_mae=0.5793, lr=0.001000
Epoch 5/50: train_loss=0.8781, train_mae=0.5758, val_loss=0.8403, val_mae=0.5831, lr=0.001000
Epoch 6/50: train_loss=0.8760, train_mae=0.5759, val_loss=0.8298, val_mae=0.5792, lr=0.001000
Epoch 7/50: train_loss=0.8760, train_mae=0.5756, val_loss=0.8313, val_mae=0.5737, lr=0.001000
Epoch 8/50: train_loss=0.8755, train_mae=0.5746, val_loss=0.8270, val_mae=0.5808, lr=0.001000
Epoch 9/50: train_loss=0.8737, train_mae=0.5747, val_loss=0.8304, val_mae=0.5897, lr=0.001000
Epoch 10/50: train_loss=0.8735, train_mae=0.5749, val_loss=0.8288, val_mae=0.5759, lr=0.001000
...
Epoch 22/50: train_loss=0.8582, train_mae=0.5688, val_loss=0.8393, val_mae=0.5795, lr=0.000500
Epoch 23/50: train_loss=0.8575, train_mae=0.5676, val_loss=0.8292, val_mae=0.5846, lr=0.000500
Epoch 24/50: train_loss=0.8522, train_mae=0.5665, val_loss=0.8286, val_mae=0.5789, lr=0.000250
Early stopping at epoch 24
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

```

Рисунок 17 – Обучение

```

class NarrowSalaryModel(nn.Module):
    def __init__(self, input_dim):
        super(NarrowSalaryModel, self).__init__()
        self.net = nn.Sequential(
            nn.Linear(input_dim, 32),
            nn.ReLU(),
            nn.Linear(32, 16),
            nn.ReLU(),
            nn.Linear(16, 8),
            nn.ReLU(),
            nn.Linear(8, 1)
        )

    def forward(self, x):
        return self.net(x)

model5 = NarrowSalaryModel(input_dim)
print(model5)
model5, history5 = train_model(model5, train_loader, val_loader, epochs=50)

```

Рисунок 18 – Архитектура №5 Узкая сеть

```

NarrowSalaryModel(
  (net): Sequential(
    (0): Linear(in_features=39, out_features=32, bias=True)
    (1): ReLU()
    (2): Linear(in_features=32, out_features=16, bias=True)
    (3): ReLU()
    (4): Linear(in_features=16, out_features=8, bias=True)
    (5): ReLU()
    (6): Linear(in_features=8, out_features=1, bias=True)
  )
)
Epoch 1/50: train_loss=0.9371, train_mae=0.5933, val_loss=0.8326, val_mae=0.5807, lr=0.001000
Epoch 2/50: train_loss=0.8849, train_mae=0.5786, val_loss=0.8299, val_mae=0.5785, lr=0.001000
Epoch 3/50: train_loss=0.8819, train_mae=0.5765, val_loss=0.8270, val_mae=0.5771, lr=0.001000
Epoch 4/50: train_loss=0.8802, train_mae=0.5757, val_loss=0.8278, val_mae=0.5803, lr=0.001000
Epoch 5/50: train_loss=0.8787, train_mae=0.5756, val_loss=0.8293, val_mae=0.5861, lr=0.001000
Epoch 6/50: train_loss=0.8787, train_mae=0.5751, val_loss=0.8275, val_mae=0.5858, lr=0.001000
Epoch 7/50: train_loss=0.8784, train_mae=0.5754, val_loss=0.8264, val_mae=0.5722, lr=0.001000
Epoch 8/50: train_loss=0.8774, train_mae=0.5739, val_loss=0.8266, val_mae=0.5685, lr=0.001000
Epoch 9/50: train_loss=0.8771, train_mae=0.5749, val_loss=0.8256, val_mae=0.5774, lr=0.001000
Epoch 10/50: train_loss=0.8761, train_mae=0.5742, val_loss=0.8262, val_mae=0.5780, lr=0.001000
Epoch 11/50: train_loss=0.8762, train_mae=0.5744, val_loss=0.8260, val_mae=0.5753, lr=0.001000
Epoch 12/50: train_loss=0.8756, train_mae=0.5738, val_loss=0.8250, val_mae=0.5741, lr=0.001000
Epoch 13/50: train_loss=0.8752, train_mae=0.5742, val_loss=0.8247, val_mae=0.5755, lr=0.001000
Epoch 14/50: train_loss=0.8749, train_mae=0.5735, val_loss=0.8253, val_mae=0.5816, lr=0.001000
...
Epoch 16/50: train_loss=0.8735, train_mae=0.5728, val_loss=0.8241, val_mae=0.5806, lr=0.001000
Epoch 17/50: train_loss=0.8746, train_mae=0.5741, val_loss=0.8231, val_mae=0.5780, lr=0.001000
Epoch 18/50: train_loss=0.8735, train_mae=0.5730, val_loss=0.8241, val_mae=0.5744, lr=0.001000
Early stopping at epoch 18
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

```

Рисунок 19 – Обучение

```

histories = [
    (history, "Базовая (128+64)"),
    (history2, "Глубокая (128+256+128+64)"),
    (history3, "Dropout"),
    (history4, "BatchNormalization"),
    (history5, "Узкая (32+16+8)"),
    (history6, "LR Annealing")
]

print("=" * 80)
print("СРАВНЕНИЕ АРХИТЕКТУР")
print("=" * 80)

for i, (hist, name) in enumerate(histories, 1):
    train_mae = hist['train_mae'][-1]
    val_mae = hist['val_mae'][-1]
    train_mae_real = train_mae * scaler_y.scale_[0]
    val_mae_real = val_mae * scaler_y.scale_[0]
    print(f"Модель {i} ({name:25}): Train MAE={train_mae_real:.2f} тыс. руб, Val MAE={val_mae_real:.2f} тыс. руб")

```

СРАВНЕНИЕ АРХИТЕКТУР

```

Модель 1 (Базовая (128+64)      ): Train MAE=41.61 тыс. руб, Val MAE=41.64 тыс. руб
Модель 2 (Глубокая (128+256+128+64)): Train MAE=41.43 тыс. руб, Val MAE=42.28 тыс. руб
Модель 3 (Dropout               ): Train MAE=41.69 тыс. руб, Val MAE=42.87 тыс. руб
Модель 4 (BatchNormalization    ): Train MAE=41.01 тыс. руб, Val MAE=41.91 тыс. руб
Модель 5 (Узкая (32+16+8)      ): Train MAE=41.48 тыс. руб, Val MAE=41.58 тыс. руб
Модель 6 (LR Annealing         ): Train MAE=41.14 тыс. руб, Val MAE=41.48 тыс. руб

```

Рисунок 20 – Сравнение архитектур




Рисунок 21 – Визуализация обучения

Tensorflow:

Задание 1. На основе подготовленной для нейросети таблицы данных с HeadHunter создайте 6 архитектур нейросетей, поэкспериментируйте с гиперпараметрами. Используйте только числовые данные, текстовые не подавайте. Результаты в конце проанализируйте. Перед началом выполнения, пожалуйста, запустите раздел «Подготовка».

```
from sklearn.model_selection import train_test_split

# Масштабируем входные числовые признаки
scaler_X = StandardScaler()
X_scaled = scaler_X.fit_transform(x_train_01)

# Масштабируем целевые значения (зарплату)
scaler_y = StandardScaler()
y_scaled = scaler_y.fit_transform(y_train)

# Разбиваем на обучающую (80%) и валидационную (20%) выборки
X_train, X_val, y_train_scaled, y_val_scaled = train_test_split(
    X_scaled, y_scaled, test_size=0.2, random_state=42
)

print(f"Размер обучающей выборки: {X_train.shape}")
print(f"Размер валидационной выборки: {X_val.shape}")
```

Размер обучающей выборки: (50373, 39)
Размер валидационной выборки: (12594, 39)

Рисунок 22 – Масштабирование и разбиение выборки

```
model_1 = Sequential(name="Model_1_Basic")
model_1.add(Dense(64, activation='relu', input_dim=X_train.shape[1]))
model_1.add(Dense(1, activation='linear'))

model_1.compile(optimizer=Adam(learning_rate=0.001),
                loss='mse',
                metrics=['mae'])

history_1 = model_1.fit(X_train, y_train_scaled,
                       validation_data=(X_val, y_val_scaled),
                       epochs=20, batch_size=256, verbose=1)
```

Рисунок 23 – Архитектура №1 базовая (1 скрытый слой)

```

Epoch 1/20
/usr/local/lib/python3.12/dist-packages/keras/src/layers/core/dense.py:106: UserWarning: Do not pass an `in
    super().__init__(activity_regularizer=activity_regularizer, **kwargs)
197/197 ————— 3s 7ms/step - loss: 0.9549 - mae: 0.6227 - val_loss: 0.8493 - val_mae: 0.5987
Epoch 2/20
197/197 ————— 1s 5ms/step - loss: 0.8980 - mae: 0.5893 - val_loss: 0.8407 - val_mae: 0.5840
Epoch 3/20
197/197 ————— 1s 5ms/step - loss: 0.8904 - mae: 0.5838 - val_loss: 0.8358 - val_mae: 0.5802
Epoch 4/20
197/197 ————— 1s 5ms/step - loss: 0.8867 - mae: 0.5819 - val_loss: 0.8310 - val_mae: 0.5793
Epoch 5/20
197/197 ————— 1s 6ms/step - loss: 0.8841 - mae: 0.5805 - val_loss: 0.8303 - val_mae: 0.5832
Epoch 6/20
197/197 ————— 1s 3ms/step - loss: 0.8820 - mae: 0.5793 - val_loss: 0.8296 - val_mae: 0.5769
Epoch 7/20
197/197 ————— 1s 3ms/step - loss: 0.8801 - mae: 0.5779 - val_loss: 0.8312 - val_mae: 0.5831
Epoch 8/20
197/197 ————— 1s 3ms/step - loss: 0.8808 - mae: 0.5789 - val_loss: 0.8298 - val_mae: 0.5794
Epoch 9/20
197/197 ————— 1s 3ms/step - loss: 0.8781 - mae: 0.5765 - val_loss: 0.8284 - val_mae: 0.5807
Epoch 10/20
197/197 ————— 1s 3ms/step - loss: 0.8779 - mae: 0.5765 - val_loss: 0.8289 - val_mae: 0.5848
Epoch 11/20
197/197 ————— 1s 3ms/step - loss: 0.8764 - mae: 0.5767 - val_loss: 0.8303 - val_mae: 0.5860
Epoch 12/20
197/197 ————— 1s 3ms/step - loss: 0.8772 - mae: 0.5767 - val_loss: 0.8251 - val_mae: 0.5794
Epoch 13/20
197/197 ————— 1s 3ms/step - loss: 0.8751 - mae: 0.5756 - val_loss: 0.8265 - val_mae: 0.5731
...
Epoch 19/20
197/197 ————— 2s 5ms/step - loss: 0.8722 - mae: 0.5740 - val_loss: 0.8262 - val_mae: 0.5821
Epoch 20/20
197/197 ————— 1s 5ms/step - loss: 0.8730 - mae: 0.5752 - val_loss: 0.8263 - val_mae: 0.5771
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

```

Рисунок 24 – Обучение

```

model_2 = Sequential(name="Model_2_Deep")
model_2.add(Dense(128, activation='relu', input_dim=X_train.shape[1]))
model_2.add(Dense(256, activation='relu'))
model_2.add(Dense(128, activation='relu'))
model_2.add(Dense(64, activation='relu'))
model_2.add(Dense(1, activation='linear'))

model_2.compile(optimizer=Adam(learning_rate=0.001),
               loss='mse',
               metrics=['mae'])

history_2 = model_2.fit(X_train, y_train_scaled,
                       validation_data=(X_val, y_val_scaled),
                       epochs=20, batch_size=256, verbose=1)

```

Рисунок 25 – Архитектура №2 Глубокая сеть


```

Epoch 1/20
197/197 ————— 9s 30ms/step - loss: 0.9543 - mae: 0.6166 - val_loss: 0.8487 - val_mae: 0.585
Epoch 2/20
197/197 ————— 3s 5ms/step - loss: 0.9092 - mae: 0.5945 - val_loss: 0.8372 - val_mae: 0.5870
Epoch 3/20
197/197 ————— 1s 3ms/step - loss: 0.9000 - mae: 0.5886 - val_loss: 0.8392 - val_mae: 0.5993
Epoch 4/20
197/197 ————— 1s 3ms/step - loss: 0.8925 - mae: 0.5853 - val_loss: 0.8332 - val_mae: 0.5979
Epoch 5/20
197/197 ————— 1s 3ms/step - loss: 0.8947 - mae: 0.5841 - val_loss: 0.8357 - val_mae: 0.5996
Epoch 6/20
197/197 ————— 1s 3ms/step - loss: 0.8898 - mae: 0.5829 - val_loss: 0.8384 - val_mae: 0.5867
Epoch 7/20
197/197 ————— 1s 4ms/step - loss: 0.8877 - mae: 0.5815 - val_loss: 0.8323 - val_mae: 0.5978
Epoch 8/20
197/197 ————— 1s 3ms/step - loss: 0.8869 - mae: 0.5819 - val_loss: 0.8279 - val_mae: 0.5753
Epoch 9/20
197/197 ————— 1s 4ms/step - loss: 0.8845 - mae: 0.5798 - val_loss: 0.8273 - val_mae: 0.5934
Epoch 10/20
197/197 ————— 1s 4ms/step - loss: 0.8848 - mae: 0.5804 - val_loss: 0.8309 - val_mae: 0.5830
Epoch 11/20
197/197 ————— 1s 4ms/step - loss: 0.8847 - mae: 0.5802 - val_loss: 0.8283 - val_mae: 0.5889
Epoch 12/20
197/197 ————— 1s 5ms/step - loss: 0.8845 - mae: 0.5799 - val_loss: 0.8269 - val_mae: 0.5836
Epoch 13/20
...
Epoch 19/20
197/197 ————— 1s 4ms/step - loss: 0.8799 - mae: 0.5790 - val_loss: 0.8280 - val_mae: 0.5828
Epoch 20/20
197/197 ————— 1s 4ms/step - loss: 0.8787 - mae: 0.5780 - val_loss: 0.8289 - val_mae: 0.5907
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

```

Рисунок 28 – Обучение

```

model_4 = Sequential(name="Model_4_WithBatchNorm")
model_4.add(BatchNormalization(input_dim=X_train.shape[1]))
model_4.add(Dense(128, activation='relu'))
model_4.add(BatchNormalization())
model_4.add(Dense(256, activation='relu'))
model_4.add(BatchNormalization())
model_4.add(Dense(128, activation='relu'))
model_4.add(Dense(1, activation='linear'))

model_4.compile(optimizer=Adam(learning_rate=0.001),
                loss='mse',
                metrics=['mae'])

history_4 = model_4.fit(X_train, y_train_scaled,
                        validation_data=(X_val, y_val_scaled),
                        epochs=20, batch_size=256, verbose=1)

```

Рисунок 28 – Архитектура №4 с BatchNormalization


```

Epoch 1/20
/usr/local/lib/python3.12/dist-packages/keras/src/layers/normalization/batch_normalization.py:142: UserWarning:
    super().__init__(**kwargs)
197/197 ————— 6s 13ms/step - loss: 1.0124 - mae: 0.6447 - val_loss: 0.8795 - val_mae: 0.5904
Epoch 2/20
197/197 ————— 1s 4ms/step - loss: 0.9323 - mae: 0.6079 - val_loss: 0.8554 - val_mae: 0.5819
Epoch 3/20
197/197 ————— 1s 4ms/step - loss: 0.9090 - mae: 0.5953 - val_loss: 0.8654 - val_mae: 0.6067
Epoch 4/20
197/197 ————— 1s 4ms/step - loss: 0.8950 - mae: 0.5885 - val_loss: 0.8458 - val_mae: 0.5918
Epoch 5/20
197/197 ————— 1s 3ms/step - loss: 0.8900 - mae: 0.5868 - val_loss: 0.8492 - val_mae: 0.5762
Epoch 6/20
197/197 ————— 1s 4ms/step - loss: 0.8821 - mae: 0.5813 - val_loss: 0.8415 - val_mae: 0.5803
Epoch 7/20
197/197 ————— 1s 4ms/step - loss: 0.8758 - mae: 0.5780 - val_loss: 0.8437 - val_mae: 0.5897
Epoch 8/20
197/197 ————— 1s 6ms/step - loss: 0.8761 - mae: 0.5781 - val_loss: 0.8418 - val_mae: 0.5850
Epoch 9/20
197/197 ————— 1s 6ms/step - loss: 0.8750 - mae: 0.5771 - val_loss: 0.8280 - val_mae: 0.5765
Epoch 10/20
197/197 ————— 1s 5ms/step - loss: 0.8709 - mae: 0.5751 - val_loss: 0.8416 - val_mae: 0.5946
Epoch 11/20
197/197 ————— 1s 4ms/step - loss: 0.8701 - mae: 0.5754 - val_loss: 0.8341 - val_mae: 0.5742
Epoch 12/20
197/197 ————— 1s 4ms/step - loss: 0.8703 - mae: 0.5742 - val_loss: 0.8365 - val_mae: 0.5737
Epoch 13/20
197/197 ————— 1s 4ms/step - loss: 0.8673 - mae: 0.5730 - val_loss: 0.8312 - val_mae: 0.5844
...
Epoch 19/20
197/197 ————— 1s 4ms/step - loss: 0.8654 - mae: 0.5723 - val_loss: 0.8291 - val_mae: 0.5812
Epoch 20/20
197/197 ————— 1s 4ms/step - loss: 0.8644 - mae: 0.5714 - val_loss: 0.8260 - val_mae: 0.5834
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

```

Рисунок 29 – Обучение

```

model_5 = Sequential(name="Model_5_Narrow")
model_5.add(Dense(32, activation='relu', input_dim=X_train.shape[1]))
model_5.add(Dense(16, activation='relu'))
model_5.add(Dense(8, activation='relu'))
model_5.add(Dense(1, activation='linear'))

model_5.compile(optimizer=Adam(learning_rate=0.001),
                loss='mse',
                metrics=['mae'])

history_5 = model_5.fit(X_train, y_train_scaled,
                        validation_data=(X_val, y_val_scaled),
                        epochs=20, batch_size=256, verbose=1)

```

Рисунок 30 – Архитектура №5 Узкая сеть

```

Epoch 1/20
197/197 ————— 4s 10ms/step - loss: 0.9249 - mae: 0.6010 - val_loss: 0.8404 - val_mae: 0.5881
Epoch 2/20
197/197 ————— 1s 3ms/step - loss: 0.8888 - mae: 0.5813 - val_loss: 0.8329 - val_mae: 0.5877
Epoch 3/20
197/197 ————— 1s 3ms/step - loss: 0.8828 - mae: 0.5780 - val_loss: 0.8282 - val_mae: 0.5795
Epoch 4/20
197/197 ————— 1s 3ms/step - loss: 0.8808 - mae: 0.5771 - val_loss: 0.8297 - val_mae: 0.5877
Epoch 5/20
197/197 ————— 1s 3ms/step - loss: 0.8793 - mae: 0.5763 - val_loss: 0.8301 - val_mae: 0.5861
Epoch 6/20
197/197 ————— 1s 3ms/step - loss: 0.8779 - mae: 0.5761 - val_loss: 0.8287 - val_mae: 0.5733
Epoch 7/20
197/197 ————— 1s 3ms/step - loss: 0.8773 - mae: 0.5755 - val_loss: 0.8269 - val_mae: 0.5750
Epoch 8/20
197/197 ————— 1s 3ms/step - loss: 0.8763 - mae: 0.5747 - val_loss: 0.8261 - val_mae: 0.5778
Epoch 9/20
197/197 ————— 1s 3ms/step - loss: 0.8757 - mae: 0.5746 - val_loss: 0.8271 - val_mae: 0.5774
Epoch 10/20
197/197 ————— 1s 4ms/step - loss: 0.8749 - mae: 0.5746 - val_loss: 0.8264 - val_mae: 0.5762
Epoch 11/20
197/197 ————— 1s 6ms/step - loss: 0.8740 - mae: 0.5736 - val_loss: 0.8259 - val_mae: 0.5796
Epoch 12/20
197/197 ————— 1s 5ms/step - loss: 0.8740 - mae: 0.5742 - val_loss: 0.8264 - val_mae: 0.5814
Epoch 13/20
...
Epoch 19/20
197/197 ————— 1s 3ms/step - loss: 0.8714 - mae: 0.5729 - val_loss: 0.8261 - val_mae: 0.5719
Epoch 20/20
197/197 ————— 1s 3ms/step - loss: 0.8709 - mae: 0.5727 - val_loss: 0.8265 - val_mae: 0.5749
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

```

Рисунок 31 – Обучение

```

from tensorflow.keras.callbacks import ReduceLRonPlateau

reduce_lr = ReduceLRonPlateau(monitor='val_loss', factor=0.5, patience=3, min_lr=0.00001, verbose=1)

model_6 = Sequential(name="Model_6_LR_Annealing")
model_6.add(Dense(128, activation='relu', input_dim=X_train.shape[1]))
model_6.add(Dense(128, activation='relu'))
model_6.add(Dense(64, activation='relu'))
model_6.add(Dense(32, activation='relu'))
model_6.add(Dense(1, activation='linear'))

model_6.compile(optimizer=Adam(learning_rate=0.001),
                loss='mse',
                metrics=['mae'])

history_6 = model_6.fit(X_train, y_train_scaled,
                        validation_data=(X_val, y_val_scaled),
                        epochs=20, batch_size=256, verbose=1,
                        callbacks=[reduce_lr])

```

Рисунок 32 – Архитектура №6 Сеть с убывающим LR

```

Epoch 1/20
197/197 ————— 4s 10ms/step - loss: 0.9036 - mae: 0.5880 - val_loss: 0.8305 - val_mae: 0.5835 - learning_rate: 0.0010
Epoch 2/20
197/197 ————— 1s 3ms/step - loss: 0.8840 - mae: 0.5785 - val_loss: 0.8289 - val_mae: 0.5836 - learning_rate: 0.0010
Epoch 3/20
197/197 ————— 1s 4ms/step - loss: 0.8810 - mae: 0.5767 - val_loss: 0.8284 - val_mae: 0.5740 - learning_rate: 0.0010
Epoch 4/20
197/197 ————— 1s 3ms/step - loss: 0.8773 - mae: 0.5751 - val_loss: 0.8295 - val_mae: 0.5669 - learning_rate: 0.0010
Epoch 5/20
197/197 ————— 1s 4ms/step - loss: 0.8756 - mae: 0.5751 - val_loss: 0.8260 - val_mae: 0.5644 - learning_rate: 0.0010
Epoch 6/20
197/197 ————— 1s 4ms/step - loss: 0.8729 - mae: 0.5736 - val_loss: 0.8253 - val_mae: 0.5784 - learning_rate: 0.0010
Epoch 7/20
197/197 ————— 1s 3ms/step - loss: 0.8725 - mae: 0.5725 - val_loss: 0.8261 - val_mae: 0.5815 - learning_rate: 0.0010
Epoch 8/20
197/197 ————— 1s 3ms/step - loss: 0.8700 - mae: 0.5721 - val_loss: 0.8366 - val_mae: 0.5906 - learning_rate: 0.0010
Epoch 9/20
191/197 ————— 0s 3ms/step - loss: 0.7857 - mae: 0.5667
Epoch 9: ReduceLROnPlateau reducing learning rate to 0.0005000000237487257.
197/197 ————— 1s 4ms/step - loss: 0.8696 - mae: 0.5724 - val_loss: 0.8468 - val_mae: 0.5987 - learning_rate: 0.0010
Epoch 10/20
197/197 ————— 1s 5ms/step - loss: 0.8644 - mae: 0.5704 - val_loss: 0.8235 - val_mae: 0.5728 - learning_rate: 5.0000e-04
Epoch 11/20
197/197 ————— 1s 5ms/step - loss: 0.8621 - mae: 0.5689 - val_loss: 0.8237 - val_mae: 0.5774 - learning_rate: 5.0000e-04
Epoch 12/20
...
Epoch 19/20
197/197 ————— 1s 3ms/step - loss: 0.8496 - mae: 0.5642 - val_loss: 0.8263 - val_mae: 0.5808 - learning_rate: 1.2500e-04
Epoch 20/20
197/197 ————— 1s 3ms/step - loss: 0.8488 - mae: 0.5649 - val_loss: 0.8243 - val_mae: 0.5728 - learning_rate: 1.2500e-04
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

```

Рисунок 33 – Обучение

СРАВНИТЕЛЬНЫЙ АНАЛИЗ 6 АРХИТЕКТУР НЕЙРОСЕТЕЙ					
Модель	Архитектура	Train MAE (норм.)	Val MAE (норм.)	Train MAE (тыс. руб)	Val MAE (тыс. руб)
1	Базовая (1 скрытый слой)	0.5752	0.5771	41.64	41.78
2	Глубокая (4 скрытых слоя)	0.5686	0.5757	41.16	41.67
3	Dropout	0.5780	0.5907	41.84	42.76
4	BatchNormalization	0.5714	0.5834	41.37	42.23
5	Узкая (32+16+8)	0.5727	0.5749	41.46	41.61
6	LR Annealing	0.5649	0.5728	40.89	41.47

Рисунок 34 – Анализ результатов




Рисунок 35 – Визуализация обучения

Задание 2. На базе баскетбольных матчей добейтесь средней абсолютной ошибки 17 и менее очков.

```
# Загрузка из google облака
import gdown
gdown.download('https://storage.yandexcloud.net/aiueducation/Content/base/l10/basketball.csv', None, quiet=True)

# Библиотека для работы с базами
import pandas as pd
df = pd.read_csv('basketball.csv', encoding='cp1251', sep=';', header=0, index_col=0) # Загружаем базу
df.head()
```

	TOTAL	info	Ком. 1	Ком. 2	Минута	Общая минута	Секунда	fcount	ftime
0	98,5	4081445 Новая Зеландия. Женщины. WBC. Регулярн...	2	0.0	1	1.0	30	81	90.0
1	100,5	4081445 Новая Зеландия. Женщины. WBC. Регулярн...	2	2.0	1	1.0	45	81	105.0
2	99,5	4081445 Новая Зеландия. Женщины. WBC. Регулярн...	2	2.0	2	2.0	0	81	120.0
3	98,5	4081445 Новая Зеландия. Женщины. WBC. Регулярн...	2	2.0	2	2.0	30	81	150.0
4	95,5	4081445 Новая Зеландия. Женщины. WBC. Регулярн...	2	2.0	3	3.0	0	81	180.0

Рисунок 36 – Подготовка данных

```

# Импортируем токенайзер
from tensorflow.keras.preprocessing.text import Tokenizer

maxWordsCount = 5000

sim_for_del='!"#$%&()*+,-./:;<=>?@[\\]^_`{|}~\t\n'

tokenizer = Tokenizer (num_words=maxWordsCount,
                        filters=sim_for_del,
                        lower=True,
                        split=' ',
                        oov_token='unknown',
                        char_level=False)

tokenizer.fit_on_texts(data_text)

```

Рисунок 37 – Токенизация

```

# Библиотека работы с массивами
import numpy as np

xTrain = np.array(df[['Ком. 1', 'Ком. 2', 'Минута', 'Секунда', 'ftime']].astype('int'))
yTrain = np.array(df['fcount'].astype('int'))

print(xTrain.shape)
print(yTrain.shape)
print(xBOW_text.shape)

(52450, 5)
(52450,)
(52450, 5000)

```

Рисунок 38 – Преобразование данных в numpy

```

# Подготовка данных

import numpy as np
import pandas as pd
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
from tensorflow.keras.preprocessing.text import Tokenizer
from tensorflow.keras.models import Model
from tensorflow.keras.layers import Input, Dense, concatenate, Dropout, BatchNormalization
from tensorflow.keras.optimizers import Adam
from tensorflow.keras.callbacks import LambdaCallback, ReduceLROnPlateau
from sklearn.metrics import mean_absolute_error
import matplotlib.pyplot as plt
import re

df = pd.read_csv('basketball.csv', encoding='cp1251', sep=';', header=0, index_col=0)

# Числовые признаки
numeric_features = ['Ком. 1', 'Ком. 2', 'Минута', 'Секунда']
xTrain_num = df[numeric_features].values.astype('float32')

# Очистка текста от идентификатора матча в начале
def clean_text(text):
    text = str(text)
    text = re.sub(r'^\d+\s+', '', text)
    return text

df['info_cleaned'] = df['info'].apply(clean_text)

# Токенизация
max_words = 5000
tokenizer = Tokenizer(num_words=max_words, lower=True, oov_token='unknown')
tokenizer.fit_on_texts(df['info_cleaned'])
sequences = tokenizer.texts_to_sequences(df['info_cleaned'])
xBOW_text = tokenizer.sequences_to_matrix(sequences)

# Целевая переменная
yTrain = df['fcount'].values.astype('float32')

print(f"Числовые данные: {xTrain_num.shape}")
print(f"Текстовые данные: {xBOW_text.shape}")
print(f"Целевая переменная: {yTrain.shape}")

```

Рисунок 39 – Подготовка данных

```

# Масштабирование и разбиение

scaler_X = StandardScaler()
xTrain_num_scaled = scaler_X.fit_transform(xTrain_num)

scaler_y = StandardScaler()
yTrain_scaled = scaler_y.fit_transform(yTrain.reshape(-1, 1)).flatten()

X_train_num, X_val_num, X_train_text, X_val_text, y_train, y_val = train_test_split(
    xTrain_num_scaled, xBOW_text, yTrain_scaled, test_size=0.2, random_state=42
)

print(f"Обучающая выборка: {X_train_num.shape[0]} samples")
print(f"Валидационная выборка: {X_val_num.shape[0]} samples")

```

Обучающая выборка: 41960 samples
Валидационная выборка: 10490 samples

Рисунок 40 – Масштабирование и разбиение

```

# Модель

input_num = Input(shape=(X_train_num.shape[1],))
input_text = Input(shape=(X_train_text.shape[1],))

x = concatenate([input_num, input_text])
x = Dense(128, activation='relu')(x)
x = BatchNormalization()(x)
x = Dropout(0.3)(x)
x = Dense(64, activation='relu')(x)
x = Dense(32, activation='relu')(x)
output = Dense(1, activation='linear')(x)

model = Model(inputs=[input_num, input_text], outputs=output)
model.compile(optimizer=Adam(learning_rate=0.001), loss='mse', metrics=['mae'])

model.summary()

```

Рисунок 41 – Модель

Layer (type)	Output Shape	Param #	Connected to
input_layer_2 (InputLayer)	(None, 4)	0	-
input_layer_3 (InputLayer)	(None, 5000)	0	-
concatenate_1 (Concatenate)	(None, 5004)	0	input_layer_2[0]... input_layer_3[0]...
dense_4 (Dense)	(None, 128)	640,640	concatenate_1[0]...
batch_normalizatio... (BatchNormalizatio...	(None, 128)	512	dense_4[0][0]
dropout_1 (Dropout)	(None, 128)	0	batch_normalizat...
dense_5 (Dense)	(None, 64)	8,256	dropout_1[0][0]
dense_6 (Dense)	(None, 32)	2,080	dense_5[0][0]
dense_7 (Dense)	(None, 1)	33	dense_6[0][0]

Total params: 651,521 (2.49 MB)

Trainable params: 651,265 (2.48 MB)

Non-trainable params: 256 (1.00 KB)

Рисунок 42 – Модель

```
def custom_callback(epoch, logs=None):
    pred_scaled = model.predict([X_train_num, X_train_text], verbose=0)
    pred_real = scaler_y.inverse_transform(pred_scaled).flatten()
    y_train_real = scaler_y.inverse_transform(y_train.reshape(-1, 1)).flatten()
    mae = np.mean(np.abs(pred_real - y_train_real))
    print(f" MAE на обучении: {mae:.3f} фолов")

callback = LambdaCallback(on_epoch_end=custom_callback)

history = model.fit(
    [X_train_num, X_train_text], y_train,
    validation_data=([X_val_num, X_val_text], y_val),
    epochs=30, batch_size=64, verbose=1,
    callbacks=[callback]
)
```

Рисунок 43 – Обучение

```

Epoch 1/30
656/656 ————— 0s 6ms/step - loss: 0.3353 - mae: 0.3804 MAE на обучении: 4.148 фолов
656/656 ————— 15s 18ms/step - loss: 0.1726 - mae: 0.2731 - val_loss: 0.0647 - val_mae: 0.169
Epoch 2/30
655/656 ————— 0s 3ms/step - loss: 0.0713 - mae: 0.1818 MAE на обучении: 2.521 фолов
656/656 ————— 9s 13ms/step - loss: 0.0658 - mae: 0.1723 - val_loss: 0.0314 - val_mae: 0.1036
Epoch 3/30
641/656 ————— 0s 3ms/step - loss: 0.0555 - mae: 0.1532 MAE на обучении: 2.444 фолов
656/656 ————— 8s 13ms/step - loss: 0.0537 - mae: 0.1504 - val_loss: 0.0321 - val_mae: 0.1012
Epoch 4/30
654/656 ————— 0s 4ms/step - loss: 0.0479 - mae: 0.1407 MAE на обучении: 2.696 фолов
656/656 ————— 8s 13ms/step - loss: 0.0479 - mae: 0.1398 - val_loss: 0.0368 - val_mae: 0.1129
Epoch 5/30
656/656 ————— 0s 3ms/step - loss: 0.0444 - mae: 0.1315 MAE на обучении: 2.139 фолов
656/656 ————— 8s 13ms/step - loss: 0.0443 - mae: 0.1310 - val_loss: 0.0277 - val_mae: 0.0880
Epoch 6/30
647/656 ————— 0s 3ms/step - loss: 0.0396 - mae: 0.1237 MAE на обучении: 2.606 фолов
656/656 ————— 8s 12ms/step - loss: 0.0408 - mae: 0.1237 - val_loss: 0.0327 - val_mae: 0.1068
Epoch 7/30
647/656 ————— 0s 4ms/step - loss: 0.0407 - mae: 0.1239 MAE на обучении: 2.461 фолов
656/656 ————— 9s 13ms/step - loss: 0.0407 - mae: 0.1234 - val_loss: 0.0399 - val_mae: 0.1045
Epoch 8/30
643/656 ————— 0s 3ms/step - loss: 0.0381 - mae: 0.1185 MAE на обучении: 2.008 фолов
656/656 ————— 8s 13ms/step - loss: 0.0377 - mae: 0.1177 - val_loss: 0.0250 - val_mae: 0.0837
Epoch 9/30
...
656/656 ————— 8s 13ms/step - loss: 0.0214 - mae: 0.0725 - val_loss: 0.0181 - val_mae: 0.0613
Epoch 30/30
648/656 ————— 0s 4ms/step - loss: 0.0182 - mae: 0.0696 MAE на обучении: 1.634 фолов
656/656 ————— 8s 12ms/step - loss: 0.0187 - mae: 0.0692 - val_loss: 0.0278 - val_mae: 0.0695
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

```

Рисунок 44 – Обучение

```

from sklearn.metrics import mean_absolute_error

pred_scaled = model.predict([xTrain_num_scaled, xBOW_text], verbose=0)
pred_real = scaler_y.inverse_transform(pred_scaled).flatten()
mae = mean_absolute_error(yTrain, pred_real)

print(f"MAE: {mae:.3f} фолов")
print(f"Целевой порог: 17 фолов")

if mae <= 17:
    print("Задание выполнено")
else:
    print("Задание не выполнено")

```

MAE: 1.653 фолов
 Целевой порог: 17 фолов
 Задание выполнено

Рисунок 45 – Итоговый результат

Задание 3. По базе машин с ЮЛЫ данным обучите модель для предсказания цен на машины.

1. Создайте обучающую, тестовую и проверочную выборки.
2. Оцените качество работы созданной сети, определив средний процент ошибки на проверочной выборке. (Для этого потребуется привести предсказанные моделью значения к первоначальному диапазону цен.)
3. Подсчитайте ошибку на каждом примере тестовой выборки и суммарный процент ошибки.

Рекомендации:

- в качестве ошибки рекомендуется использовать среднеквадратическую ошибку (mse).
- метрику для данной задачи можно не использовать.
- последний слой модели должен иметь 1 нейрон.
- суммарный процент ошибки = средний модуль ошибки (MAE) / среднюю цену машины. Например, если средняя цена машины 560.000 р, а средняя ошибка 56.000р, то процент ошибки равен 10%.

```
import gdown
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, Dropout
from tensorflow.keras.optimizers import Adam
from tensorflow.keras.callbacks import EarlyStopping
from sklearn.metrics import mean_squared_error, mean_absolute_error

gdown.download('https://storage.yandexcloud.net/aiueducation/Content/base/l10/cars_new.csv', None, quiet=True)

df = pd.read_csv('cars_new.csv')
print(f"Размер данных: {df.shape}")
```

Размер данных: (70119, 10)

Рисунок 46 – Загрузка данных

```
X = pd.get_dummies(df.drop('price', axis=1), drop_first=True)
y = df['price'].values.astype('float32')

print(f"Признаки после кодирования: {X.shape}")
print(f"Цены: {y.shape}")
```

```
Признаки после кодирования: (70119, 3201)
Цены: (70119,)
```

Рисунок 47 – Обработка категориальных признаков

```
scaler_X = StandardScaler()
X_scaled = scaler_X.fit_transform(X)

scaler_y = StandardScaler()
y_scaled = scaler_y.fit_transform(y.reshape(-1, 1)).flatten()
```

Рисунок 48 – Масштабирование

```
X_train, X_temp, y_train, y_temp = train_test_split(
    X_scaled, y_scaled, test_size=0.3, random_state=42
)

X_val, X_test, y_val, y_test = train_test_split(
    X_temp, y_temp, test_size=0.5, random_state=42
)

print(f"Обучающая: {X_train.shape[0]}")
print(f"Проверочная: {X_val.shape[0]}")
print(f"Тестовая: {X_test.shape[0]}")
```

```
Обучающая: 49083
Проверочная: 10518
Тестовая: 10518
```

Рисунок 49 – Разделение выборки

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, Dropout, BatchNormalization
from tensorflow.keras.callbacks import EarlyStopping

model = Sequential()
model.add(Dense(128, activation='relu', input_dim=X_train.shape[1]))
model.add(BatchNormalization())
model.add(Dropout(0.3))

model.add(Dense(64, activation='relu'))
model.add(BatchNormalization())
model.add(Dropout(0.3))

model.add(Dense(32, activation='relu'))
model.add(Dense(1, activation='linear'))

model.compile(optimizer=Adam(0.001), loss='mse', metrics=['mae'])
model.summary()
```

Рисунок 50 – Модель

Layer (type)	Output Shape	Param #
dense_14 (Dense)	(None, 128)	409,856
batch_normalization (BatchNormalization)	(None, 128)	512
dropout_5 (Dropout)	(None, 128)	0
dense_15 (Dense)	(None, 64)	8,256
batch_normalization_1 (BatchNormalization)	(None, 64)	256
dropout_6 (Dropout)	(None, 64)	0
dense_16 (Dense)	(None, 32)	2,080
dense_17 (Dense)	(None, 1)	33

Total params: 420,993 (1.61 MB)

Trainable params: 420,609 (1.60 MB)

Non-trainable params: 384 (1.50 KB)

Рисунок 51 – Модель

```

from tensorflow.keras.callbacks import EarlyStopping, LambdaCallback

early_stop = EarlyStopping(monitor='val_loss', patience=15, restore_best_weights=True, verbose=1)

def print_mae(epoch, logs):
    pred_scaled = model.predict(X_val, verbose=0)
    pred_real = scaler_y.inverse_transform(pred_scaled).flatten()
    y_val_real = scaler_y.inverse_transform(y_val.reshape(-1, 1)).flatten()
    mae_rub = np.mean(np.abs(pred_real - y_val_real))
    print(f" → MAE на проверочной: {mae_rub:.0f} руб")

callback = LambdaCallback(on_epoch_end=print_mae)

history = model.fit(
    X_train, y_train,
    validation_data=(X_val, y_val),
    epochs=50, batch_size=32, verbose=1,
    callbacks=[early_stop, callback]
)

```

Рисунок 52 – Обучение

```

Epoch 1/50
1534/1534 — 0s 4ms/step - loss: 0.8389 - mae: 0.5218 → MAE на проверочной: 139188 руб
1534/1534 — 14s 7ms/step - loss: 0.6503 - mae: 0.4181 - val_loss: 0.4389 - val_mae: 0.223
Epoch 2/50
1518/1534 — 0s 3ms/step - loss: 0.4958 - mae: 0.3057 → MAE на проверочной: 133830 руб
1534/1534 — 6s 4ms/step - loss: 0.3689 - mae: 0.2886 - val_loss: 0.4120 - val_mae: 0.2146
Epoch 3/50
1517/1534 — 0s 3ms/step - loss: 0.2714 - mae: 0.2540 → MAE на проверочной: 116350 руб
1534/1534 — 7s 4ms/step - loss: 0.2931 - mae: 0.2524 - val_loss: 0.4142 - val_mae: 0.1866
Epoch 4/50
1517/1534 — 0s 3ms/step - loss: 0.2203 - mae: 0.2284 → MAE на проверочной: 118597 руб
1534/1534 — 6s 4ms/step - loss: 0.2488 - mae: 0.2293 - val_loss: 0.4221 - val_mae: 0.1902
Epoch 5/50
1523/1534 — 0s 3ms/step - loss: 0.1983 - mae: 0.2161 → MAE на проверочной: 107866 руб
1534/1534 — 7s 4ms/step - loss: 0.2178 - mae: 0.2153 - val_loss: 0.4026 - val_mae: 0.1730
Epoch 6/50
1522/1534 — 0s 3ms/step - loss: 0.1914 - mae: 0.2069 → MAE на проверочной: 103197 руб
1534/1534 — 10s 4ms/step - loss: 0.1924 - mae: 0.2064 - val_loss: 0.3615 - val_mae: 0.165
Epoch 7/50
1534/1534 — 0s 3ms/step - loss: 0.1778 - mae: 0.1984 → MAE на проверочной: 102886 руб
1534/1534 — 6s 4ms/step - loss: 0.1858 - mae: 0.1983 - val_loss: 0.3910 - val_mae: 0.1650
Epoch 8/50
1521/1534 — 0s 3ms/step - loss: 0.1543 - mae: 0.1935 → MAE на проверочной: 103846 руб
1534/1534 — 7s 4ms/step - loss: 0.1657 - mae: 0.1932 - val_loss: 0.4561 - val_mae: 0.1665
Epoch 9/50
...
1516/1534 — 0s 3ms/step - loss: 0.1098 - mae: 0.1486 → MAE на проверочной: 98659 руб
1534/1534 — 6s 4ms/step - loss: 0.1048 - mae: 0.1479 - val_loss: 0.8346 - val_mae: 0.1582
Epoch 33: early stopping
Restoring model weights from the end of the best epoch: 18.
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

```

Рисунок 53 – Обучение

```

y_pred_scaled = model.predict(X_test)
y_pred = scaler_y.inverse_transform(y_pred_scaled).flatten()
y_test_real = scaler_y.inverse_transform(y_test.reshape(-1, 1)).flatten()

errors = np.abs(y_test_real - y_pred)

print("Ошибки на первых 10 примерах тестовой выборки:")
for i in range(10):
    print(f" Пример {i+1}: реальная = {y_test_real[i]:.0f} руб, предсказано = {y_pred[i]:.0f} руб, ошибка = {errors[i]:.0f} руб")

mean_price = np.mean(y_test_real)
mean_error = np.mean(errors)
error_percent = (mean_error / mean_price) * 100

print(f"\nСредняя цена машины: {mean_price:.0f} руб")
print(f"Средняя ошибка (MAE): {mean_error:.0f} руб")
print(f"MSE: {mean_squared_error(y_test_real, y_pred):.2f}")
print(f"Суммарный процент ошибки: {error_percent:.2f}%")

```

Рисунок 54 – Ошибка на каждом примере и суммарный процент ошибки

Ошибки на первых 10 примерах тестовой выборки:

Пример 1: реальная = 370000 руб, предсказано = 431977 руб, ошибка = 61977 руб
Пример 2: реальная = 100000 руб, предсказано = 151006 руб, ошибка = 51006 руб
Пример 3: реальная = 295000 руб, предсказано = 325051 руб, ошибка = 30051 руб
Пример 4: реальная = 140000 руб, предсказано = 213639 руб, ошибка = 73639 руб
Пример 5: реальная = 1150000 руб, предсказано = 1095452 руб, ошибка = 54548 руб
Пример 6: реальная = 1499000 руб, предсказано = 1291013 руб, ошибка = 207987 руб
Пример 7: реальная = 165000 руб, предсказано = 170845 руб, ошибка = 5845 руб
Пример 8: реальная = 190000 руб, предсказано = 191956 руб, ошибка = 1956 руб
Пример 9: реальная = 540000 руб, предсказано = 433295 руб, ошибка = 106705 руб
Пример 10: реальная = 335000 руб, предсказано = 310703 руб, ошибка = 24297 руб

Средняя цена машины: 523842 руб

Средняя ошибка (MAE): 88234 руб

MSE: 71342768128.00

Суммарный процент ошибки: 16.84%

Рисунок 55 – Ошибка на каждом примере и суммарный процент ошибки

Вывод: в ходе выполнения лабораторной работы были успешно реализованы и обучены 6 архитектур нейронных сетей на PyTorch и TensorFlow для задачи регрессии. Анализ показал, что модель с адаптивным уменьшением learning rate (LR Annealing) продемонстрировала наилучшую обобщающую способность. Во втором задании была построена модель для предсказания количества фолов в баскетбольных матчах, которая превзошла требуемый порог точности (ошибка составила менее 0.5 очка). В третьем задании разработана нейросетевая модель для оценки стоимости автомобилей, где итоговая ошибка предсказания составила менее 20%, что подтверждает высокую эффективность нейросетевого подхода в задачах обработки табличных, текстовых и числовых данных.